

# 求职简历

PERSONAL RESUME

## 基本信息

姓名：柯伟嘉 手机：13299776737  
年龄：24 邮箱：794293393@qq.com  
学历：大学本科 民族：汉族  
求职意向：大模型应用工程师



## 自我评价

软件工程本科，求职方向为大模型应用工程师。熟悉 RAG、Agent、NL2SQL、Prompt Engineering 等应用层开发，能围绕业务场景完成知识库构建、检索排序、Prompt 组织、模型调用、规则兜底、评测诊断和可视化演示。相比只调用模型接口，更关注系统的可控性、可解释性和可验证性。

## 教育背景

软件工程 福建理工大学 2021.09-2025.06

- 主修课程：操作系统、计算机网络、数据结构与算法、计算机组成原理、数据库设计、设计模式等。

## 技术栈

- 编程与后端：Python、FastAPI、Pydantic、Pandas、SQLite、MySQL、Git、Linux 基础。
- 大模型应用：OpenAI API / DeepSeek 兼容接口、LangChain、LangGraph、LlamaIndex、提示词工程、Tool Calling。
- RAG 与检索：FAISS、Milvus 基础、Embedding、Hybrid Retrieval、bge-reranker、Context Builder、Grounding Evaluation。
- Agent 与数据分析：NL2SQL、SQL 安全校验、规则兜底、CSV/Excel 解析、Streamlit、Plotly。
- 模型与部署：了解 Transformers、Qwen、LoRA/PEFT、Docker、vLLM、GPTQ 量化。

## 项目经历

### 项目一：企业经营数据分析 Agent | 2026.05

项目描述：面向企业经营分析、销售分析和运营分析场景，开发本地可演示的数据分析 Agent，支持自然语言问数、LLM NL2SQL、SQL 安全校验、规则兜底、FAISS 知识库检索和经营报告生成

- Agent 编排：基于 LangGraph 设计“意图识别 -> 查询规划 -> SQL 执行 -> 结果分析 -> 响应生成”的可控流程，同时保留顺序执行兜底，避免自由 Agent 失控。

- NL2SQL: 接入 OpenAI/DeepSeek 兼容接口, 通过 Schema Prompt 注入表结构、字段含义、关联关系、指标口径和业务日期规则, 约束模型输出 SQLite SELECT 查询。
- 安全与兜底: 实现只读查询、单语句限制、业务表白名单、危险关键字过滤、禁用系统时间函数; 当 LLM 不可用或输出异常时, 回退到规则 SQLPlanner。
- RAG 知识库: 使用 FAISS CPU 构建本地经营分析知识库, 沉淀 GMV、ROI、客单价、退款率、库存风险等指标口径与归因规则, 用于解释查询结果和生成报告。
- 演示界面: 使用 Streamlit 搭建本地交互界面, 支持 CSV/Excel 上传后的字段识别、数据预览、数值摘要、SQL 展示、Plotly 图表和 Markdown 经营周报输出。

### 项目二: 外卖客服 RAG 智能问答系统 | 2026.04 - 2026.05

项目描述: 面向外卖客服场景, 构建可调试、可评测、可解释的 RAG 智能问答系统, 覆盖退款售后、配送进度、食品安全、优惠券、平台安全、隐私保护等高频客服问题。

- RAG 链路: 基于 FastAPI 提供问答、检索调试、Prompt 预览、模型信息和知识库样本接口; 使用本地 Qwen2.5-1.5B-Instruct 生成中文客服回复, 并支持 LoRA adapter 检测和加载。
- Hybrid Retrieval: 结合向量检索、关键词加权和业务方向惩罚, 并接入 bge-reranker-base 进行 rerank, 缓解外卖客服中相似意图混淆问题。
- 证据组织: 在 Context Builder 中区分 primary evidence 和 supporting evidence, 提示模型优先依据最相关证据回答, 降低不同意图资料混用风险。
- 安全兜底: 针对私下转账、验证码、食品安全、退款进度、商家拒绝退款等高风险/高频场景设计 reply\_rules, 避免模型输出不合规承诺。
- 评测诊断: 构建 grounding evaluation, 记录 retrieved\_items、final\_prompt、reply、judge\_status、missing\_evidence\_keywords 等字段, 并通过 bad case 分析定位 retrieval、context builder、generation、reply rules 或 judge 层问题。
- 当前效果: 30 条 grounding 回归集上 top1\_intent\_hit\_rate 达到 1.0, evidence\_keyword\_coverage 约 0.9344, forbidden\_hit\_count 为 0。